

Weed and Anomaly Detection in Maize Fields with Deep Learning on Fragmented Orthomosaics

Abstract—This work presents the development of a computer vision pipeline for detecting anomalies in maize crops, including weeds, planting gaps, and overlapping plants. The initial dataset consisted of high-resolution orthomosaic images provided by a partner company. Due to their large size and complexity, these images were segmented into 600×600 pixel tiles, resulting in 1,316 sub-images. After assessing quality, 451 images were selected and manually annotated using a custom labeling tool developed with Pygame. Initially, the Weeds-Galore dataset and DeepLabv3 model were explored, but due to limited performance, the approach was shifted to YOLO-based object detection. The annotated dataset was divided into training, validation, and test sets, with a recommended 70/15/15 distribution. The proposed solution aims to support agricultural monitoring by automating anomaly detection in large-scale crop imagery.

Keywords—computer vision, weed detection, orthomosaic, maize crop, deep learning, YOLO, image labeling, agricultural monitoring

Resumo—Este trabalho apresenta o desenvolvimento de um pipeline de visão computacional para a detecção de anomalias em lavouras de milho, incluindo plantas daninhas, falhas no plantio (gaps) e plantas sobrepostas. O conjunto inicial de dados consistia em imagens ortomosaicas de alta resolução fornecidas por uma empresa parceira. Devido ao tamanho e complexidade das imagens, estas foram divididas em subimagens de 600×600 pixels, resultando em 1.316 imagens. Após avaliação de qualidade, 451 imagens foram selecionadas e anotadas manualmente com uma ferramenta de rotulagem desenvolvida em Pygame. Inicialmente, foi explorado o uso do conjunto de dados Weeds-Galore e do modelo DeepLabv3, mas devido à performance limitada, a abordagem foi direcionada para a detecção de objetos baseada em YOLO. O conjunto anotado foi dividido em conjuntos de treino, validação e teste, com uma distribuição recomendada de 70% treino, 15% validação e 15% teste. A solução proposta visa apoiar o monitoramento agrícola, automatizando a detecção de anomalias em imagens de grandes áreas de cultivo.

Palavras-chave—visão computacional, detecção de plantas daninhas, ortomosaico, lavoura de milho, deep learning, YOLO, rotulagem de imagens, monitoramento agrícola

I. INTRODUÇÃO

A Inteligência Artificial (IA) tem transformado profundamente a forma como interagimos com a tecnologia e com o mundo ao nosso redor. Desde assistentes virtuais até sistemas de recomendação e carros autônomos, os avanços nessa área têm proporcionado ganhos significativos em eficiência, produtividade e inovação. No entanto, esse crescimento acelerado

levanta questões importantes sobre ética, responsabilidade e impactos sociais da IA, que precisam ser considerados com igual atenção [1], [2].

O uso de IA no setor agrícola é um exemplo claro de como essas tecnologias podem ser aplicadas em contextos práticos para solucionar problemas reais. Técnicas de aprendizado profundo, como as redes neurais convolucionais (CNNs), têm se mostrado eficazes na identificação de doenças em plantas, otimizando processos e reduzindo perdas na produção agrícola [3], [4]. Essas soluções automatizadas tornam-se cada vez mais viáveis com o avanço dos modelos de detecção de objetos, como o YOLO (You Only Look Once), que permite reconhecimento em tempo real com alta precisão [5], [6].

A Figura ?? apresenta uma imagem panorâmica da plantação de milho, ilustrando o tipo de cenário analisado neste trabalho.

No entanto, a aplicação da inteligência artificial na agricultura também levanta preocupações importantes, especialmente no que diz respeito à equidade social, sustentabilidade ética e inclusão tecnológica. A adoção de tecnologias avançadas, como a visão computacional e o aprendizado profundo, pode acentuar desigualdades já existentes entre grandes produtores – que possuem maior acesso a infraestrutura, conectividade e conhecimento técnico – e pequenos agricultores, que enfrentam barreiras econômicas e educacionais significativas. A lacuna digital no campo pode, assim, se tornar um entrave à democratização dos benefícios da IA.

Além disso, a ausência de regulamentações robustas sobre o uso de IA em contextos agrícolas levanta questões críticas sobre privacidade de dados georreferenciados, responsabilidade em decisões automatizadas (por exemplo, em sistemas de pulverização autônoma) e a transparência dos modelos de machine learning utilizados – frequentemente tratados como caixas-pretas. Como apontado por Mittelstadt et al. (2016), os sistemas automatizados exigem estruturas de governança ética que assegurem não apenas desempenho técnico, mas também justiça, explicabilidade e responsabilidade social [7]. Nesse contexto, é fundamental que o desenvolvimento e a implementação dessas tecnologias considerem uma abordagem participativa e centrada no ser humano, buscando garantir que os avanços da IA na agricultura beneficiem toda a cadeia

de detecção. Essa abordagem tem se mostrado eficiente para preparar bases de dados específicas para detecção de plantas daninhas, contagem de plantas e identificação de falhas em culturas como o milho.

REFERÊNCIAS

- [1] A. Garcia, “Inteligência artificial e seus impactos éticos na sociedade,” *Revista de Ética e Tecnologia*, vol. 12, no. 2, pp. 45–60, 2020.
- [2] C. Pinto, “Responsabilidade social no uso da inteligência artificial,” *Cadernos de Tecnologia e Sociedade*, vol. 5, no. 1, pp. 22–35, 2020.
- [3] A. Kamilaris and F. X. Prenafeta-Boldú, “Deep learning in agriculture: A survey,” *Computers and Electronics in Agriculture*, vol. 147, pp. 70–90, 2018.
- [4] B. dos Santos and C. Oliveira, “Segmentação de plantas daninhas em imagens de lavouras de milho utilizando aprendizado profundo,” *Revista Brasileira de Agricultura de Precisão*, vol. 4, no. 1, pp. 12–24, 2020.
- [5] Z. Zhao, P. Zheng, S.-t. Xu, and X. Wu, “Object detection with deep learning: A review,” *IEEE Transactions on Neural Networks and Learning Systems*, vol. 30, no. 11, pp. 3212–3232, 2019.
- [6] J. Redmon and A. Farhadi, “Yolov3: An incremental improvement,” in *arXiv preprint arXiv:1804.02767*, 2018.
- [7] B. D. Mittelstadt, P. Allo, M. Taddeo, S. Wachter, and L. Floridi, “The ethics of algorithms: Mapping the debate,” *Big data & society*, vol. 3, no. 2, p. 2053951716679679, 2016.
- [8] V. Tessele and M. B. d. Oliveira Junior, “Desenvolvimento de um modelo de detecção de doenças em soja com ml.net: Análise de performance,” pp. 428–431, 2024. [Online]. Available: <https://doi.org/10.5753/latinoware.2024.245599>